

Mini Estudo 1: Baseline do Sistema Escolhido

Arthur Silva Matias - 22052559

Arthur Vinício Capucho Silva - 22351675

Giovana Lins Cavalcanti - 22352925

Link do Github do resultados: [resultados](#)

1. Pergunta

Para que tipos de consultas os sistemas tem melhor desempenho?

2. Sistema

Temos dois sistemas que usam PostgreSQL com esquemas diferentes para o mesmo conjunto de dados, implementados em container docker. Ambos usam python para controlar o SGBD com duas cargas de testes semanticamente equivalentes.

3. Métrica

A métrica principal é tuplas por milissegundo, representada pela unidade tp/ms.

4. Instrumento

Utilizaremos a biblioteca interna do python chamada time para medir diretamente o tempo para calcular as tuplas por milissegundo. Além disso, os metadados do SGBD como planos de execução e número de acessos a disco também foram salvos.

5. Benchmark

O tipo de teste é o benchmark, já que a avaliação foca em medir o desempenho baseado em tuplas por segundo de seis categorias de consultas, assim permitindo uma avaliação mais holística do desempenho do sistema.

6. Carga

Utilizaremos duas cargas de 40 consultas, uma para cada sistema, armazenadas em arquivos JSON, distribuídas nas seguintes categorias:

Categoria	Quantidade
Lookup simples	8
Filtros	8

Joins	9
Agregações	6
Group By	5
Order By	2
Subqueries	2

Cada consulta é adaptada para o esquema de ambos os sistemas, de forma a manter a equivalência semântica. Além disso, elas são armazenadas em um JSON, contendo meta informações sobre a consulta:

```
{
  "id": 1,
  "titulo": "Busca básica de produto por ASIN",
  "categoria": "Lookup Simples",
  "tipo_select": "Lookup por chave primária",
  "descricao_carga": "Consulta altamente seletiva utilizando igualdade sobre chave primária.",
  "joins": 0,
  "usa_filtro": true,
  "usa_agregacao": false,
  "usa_group_by": false,
  "usa_order_by": false,
  "usa_subquery": false,
  "seletividade": "Alta",
  "linhas_esperadas": "1 linha",
  "uso_indice": "Sim",
  "complexidade": "Baixa",
  "sql": "SELECT ASIN, TITLE, PRODUCT_GROUP, SALES_RANK, DOWNLOADED FROM PRODUCT WHERE ASIN = '0738700797';",
  "explicacao": "Recupera as informações básicas de um produto específico utilizando busca direta pela chave primária ASIN."
}
```

7. Protocolo

1. Preparar o ambiente: certificar-se que o computador alvo não está sendo utilizado para outros fins no momento, conectar-se ao servidor SSH via Tailscale, subir os containers docker e adaptar a carga para o esquema de cada sistema.
2. Executar experimentos:
 - Subir o docker
 - Popular os bancos de dados
 - Executar as consultas
 - Para mais detalhes leia o README do repositório
3. Coletar dados: para cada uma das 30 repetições, registrar o tempo de consulta, quantidade de tuplas retornadas e tuplas por milissegundo (t/ms).
4. Registrar metadados: índice do banco de dados, estado da cache, execução, cenário, carga, métrica, timestamp, observação e consulta decomposta/otimizada pelo SGBD.
5. Verificar consistência: conferir erros de execução, dados ausentes, valores impossíveis e justificativas de exclusão.

8. Análise

A análise foi feita usando os dados brutos coletados durante 30 repetições de cada uma das 40 consultas executadas nos dois sistemas. Para cada execução, foram registrados o tempo de execução da consulta, a quantidade de tuplas retornadas e a métrica principal do estudo definida como tuplas por milissegundo (tp/ms).

Primeiramente, os resultados foram agrupados por sistema para obter uma visão geral do comportamento observado. Foram calculadas as métricas de média, mediana, valor mínimo e máximo, desvio padrão e intervalo de confiança de 95% para cada sistema.

Sistema	Amstras	Média (tp/ms)	Mediana (tp/ms)	Mín. (tp/ms)	Máx. (tp/ms)	Desvio Padrão	IC 95% Inf	IC 95% Sup
Sistema Arthur	1200	207.082238	0.944695	0.000000	1906.742524	455.070474	181.308658	232.855818
Sistema Giovana	1200	212.922249	0.499748	0.005325	1687.223981	429.618422	188.590183	237.254315

Os resultados globais mostram que ambos os sistemas apresentaram desempenho médio semelhante durante os testes, com médias próximas de vazão em tp/ms. Porém os resultados também mostram variabilidade nos resultados, indicados pelos valores de desvio padrão e pela diferença grande entre média e mediana nos dois sistemas.


Essa diferença ocorre pois as consultas possuem características diferentes entre si, mesmo dentro de uma mesma categoria, onde algumas consultas devolvem poucas linhas e executam rapidamente,

enquanto outras processam grandes volumes de dados, usando operações mais custosas e executando por mais tempo. Por isso, a mediana foi considerada para representar o comportamento típico das execuções.


Os dados também foram agrupados por categoria de consulta, permitindo observar como cada sistema se comporta em diferentes tipos de carga.



Sistema	Categoria	Amostras	Média (tp/ms)	Mediana (tp/ms)	Mín. (tp/ms)	Máx. (tp/ms)	Desvio Padrão	IC 95% Inf.	IC 95% Sup.
Sistema Arthur	Agregações	180	0,017	0,007	0,005	0,039	0,014	0,015	0,019
Sistema Giovana	Agregações	180	0,016	0,007	0,005	0,038	0,014	0,014	0,018
Sistema Arthur	Filtros	240	585,725	300,295	0,000	1906,743	657,533	502,113	669,336
Sistema Giovana	Filtros	240	590,699	480,604	0,499	1687,224	537,328	522,373	659,025
Sistema Arthur	Group By	150	17,433	0,021	0,015	89,674	34,831	11,814	23,053
Sistema Giovana	Group By	150	16,719	0,022	0,015	87,984	33,439	11,324	22,114
Sistema Arthur	Joins	270	371,459	4,903	0,042	1397,432	532,357	307,673	435,246

Sistema Giovana	Joins	270	391,251	7,204	0,042	1301,874	548,484	325,532	456,970
Sistema Arthur	Lookup Simples	240	4,586	1,656	0,006	22,512	6,303	3,784	5,387
Sistema Giovana	Lookup Simples	240	4,460	1,572	0,005	22,924	6,098	3,685	5,236
Sistema Arthur	Order By	60	0,277	0,270	0,075	0,491	0,202	0,225	0,329
Sistema Giovana	Order By	60	0,088	0,086	0,072	0,107	0,014	0,085	0,092
Sistema Arthur	Subquery	60	64,926	62,999	21,991	109,480	42,304	54,000	75,854
Sistema Giovana	Subquery	60	75,244	70,023	23,702	127,093	48,888	62,615	87,873




Nas consultas de agregação, os resultados foram semelhantes entre os sistemas, mas com uma vazão levemente maior no sistema Arthur.






As categorias de Filtros, Joins e Group By apresentaram os maiores desvios padrão e diferenças expressivas entre média e mediana. Isso indica alta heterogeneidade entre as consultas dessas categorias. Em especial, nas consultas com joins, foi observado que enquanto o sistema Arthur apresentou média maior, o sistema Giovana apresentou mediana superior, sugerindo que Arthur possui algumas consultas extremamente rápidas que elevam a média geral, enquanto Giovana apresentou comportamento mais estável entre diferentes execuções.


A categoria Group By apresenta os resultados mais extremos, com boa parte das consultas caindo na categoria de outlier, isso provavelmente indica que a amostra não é grande o suficiente para resultados confiáveis.



Nas consultas de Lookup Simples, os dois sistemas apresentaram desempenho próximo, sugerindo que ambos conseguem usar de forma eficiente os índices definidos para buscas seletivas por chave primária ou atributo indexado.



Já em consultas envolvendo Order By, o sistema Arthur apresentou vazão média maior, sendo uma possível explicação a quantidade pequena de consultas nessa categoria na amostra, o que torna o resultado pouco confiável. Nas consultas com Subqueries, o sistema Giovana apresentou vazão média superior nas condições avaliadas, de forma consistente ao longo das execuções como apontada pela mediana.



Na categoria Subquery o Sistema Giovana tem vazões maiores e maior dispersão entre as consultas, mas como podemos ver ambos têm medianas próximas. No geral, nessa categoria o sistema Giovana apresenta melhor desempenho.

9. Conclusão

Os resultados obtidos durante o benchmark mostram que os dois sistemas apresentam desempenho geral semelhante quando analisados de forma agregada, com médias próximas de tuplas por milissegundo ao longo das execuções realizadas. Porém a análise por categoria mostrou que o comportamento dos sistemas varia de acordo com o tipo de consulta executada.

Nas consultas mais simples e altamente seletivas, ambos os sistemas apresentam desempenho próximo, indicando uso eficiente de índices e baixo impacto das diferenças estruturais entre os esquemas dos sistemas.

Já operações mais complexas como Order By, Group By e Subqueries, as diferenças mais perceptíveis começaram a aparecer, sugerindo que o baixo número de amostras tem alto impacto nessas categorias mais do que as outras.

Os resultados mostraram também variabilidade alta em algumas categorias como Filtro, Joins e Group By, evidenciado pelos altos desvios padrão e pela diferença significativa entre média e mediana, indicando que consultas semanticamente agrupadas ainda podem possuir custos diferentes.

De forma geral, o baseline construído permitiu estabelecer uma referência inicial de desempenho para os dois sistemas avaliados sob uma carga controlada e com cache quente. Os resultados sugerem que não existe um sistema universalmente melhor para todas as consultas, já que o desempenho observado depende diretamente das características da operação realizada e da forma como cada esquema organiza os seus dados.

Por fim, o estudo permitiu validar o protocolo de coleta, as ferramentas usadas e a caracterização da carga de trabalho, fornecendo uma base experimental para análises futuras.

10. Limitações

Como uma análise superficial, não interpretamos os metadados nesse primeiro mini estudo. Porém, esses dados foram coletados para todas as consultas.

A carga é sintética, pois apesar de desejarmos testar com uma carga realista, é inviável descobrir como seriam consultas reais no banco de dados da Amazon.

Número de consultas baixo, o que inviabiliza uma comparação confiável entre os dois sistemas.

Consultas concorrentes não foram e não serão testadas, pois os sistemas não foram desenvolvidos com esse intuito. Antes da coleta das amostras, foi realizada uma fase de warmup para carregar páginas e índices em memória, para reduzir o impacto de leituras.

O estudo usa somente o PostgreSQL, fazendo com que os resultados obtidos dependem diretamente das estratégias internas de otimização adotadas pelo Postgre.

Em suma, os dados e a análise são relevantes apenas aos sistemas didáticos testados e não refletem a situação de um banco de dados em produção, com carga diferente, com concorrência ou com cargas cuja mistura de consultas difere daquelas usadas nos testes.